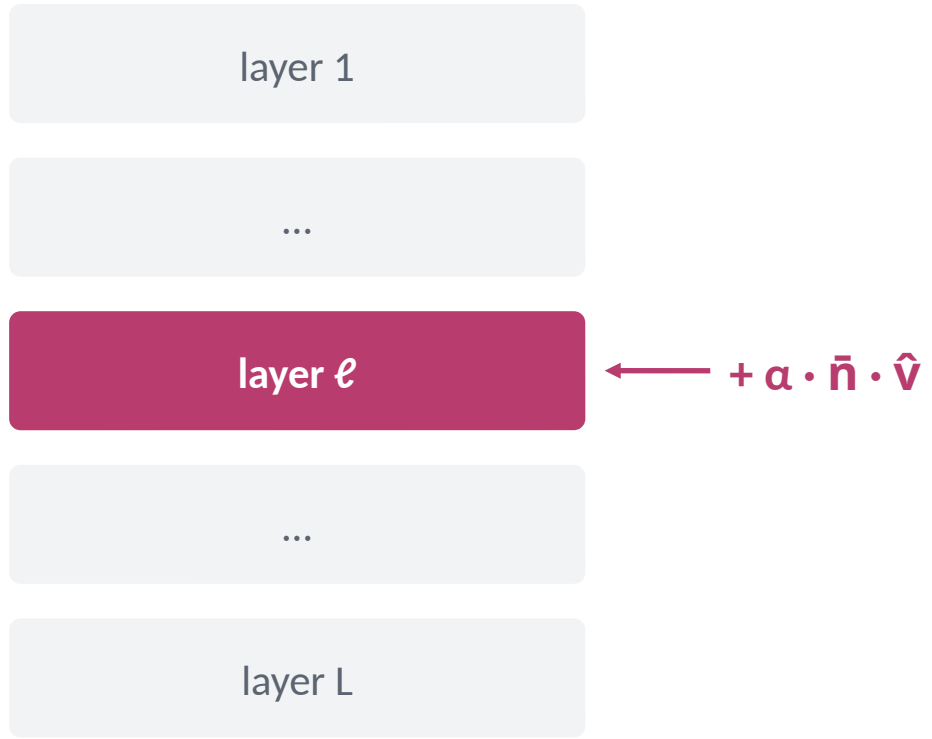
Do Emotions Affect LLM’s Performance on Question-Answering Tasks?

Effetto dell'activation steering emotivo su conoscenza fattuale e inferenza degli LLM

Fabio Cirullo · Deep Learning · Università di Bari Aldo Moro

Activation steering

- Nei LLM molti concetti (sentiment, verità, rifiuto) corrispondono a direzioni quasi lineari nelle attivazioni.
- Aggiungendo un vettore al residual stream di un layer durante l'inferenza si orienta il comportamento del modello.
- Niente fine-tuning e niente modifiche al prompt: è economico e funziona su qualsiasi modello open-weight.
- Per le emozioni è utile in agenti conversazionali empatici o in agenti per il role-play.



v̂: direzione dell'emozione, α: forza, n̄: norma media delle attivazioni

Lo stile emotivo ha un costo sui fatti?

Il vettore viene aggiunto a una rappresentazione che il modello usa anche per ricordare i fatti. Se rendere un modello felice o triste cambia le sue risposte, lo steering diventa un compromesso tra stile e affidabilità.

RQ1

Quali layer rappresentano le emozioni in modo lineare, e sono quindi candidati per lo steering?

RQ2

Per ogni emozione e layer, quale forza rende l'emozione visibile senza rompere il testo?

RQ3

Come cambia la conoscenza fattuale e l’inferenza quando lo steering avviene a profondità diverse?

Lavori precedenti misurano gli effetti collaterali su altri tratti o benchmark generali e spesso usano una sola forza per tutti i concetti.

Pipeline del progetto

1 → 2 → 3 → 4 → 5

Attivazioni

Residual stream dell'ultimo token, a ogni layer

Probe lineari

Un classificatore per layer: dove le emozioni sono separabili

Vettori

Difference of Means: emozione contro le altre nove

Forza α

Calibrata a mano sulla generazione libera

BeliefBank

Risposte sì/no con e senza steering

Modelli

- Qwen2.5-7B-Instruct: 28 layer, 4-bit
- Llama-3.1-8B-Instruct: 32 layer, 4-bit
- Qwen3.8-27B: 64 layer, bf16 (Modal, A100)

Dati

- EmpatheticDialogues: 10 emozioni, situazioni in prima persona
- BBF: fatti semplici (“an albatross is a bird”)
- BBC: vincoli tra concetti (“if … then …”)

Forza calibrata per ogni condizione

- α cresce a passi di 0.1 su 4 prompt neutri, con decodifica greedy
- α_break: primo valore in cui un testo si rompe (ripetizioni, caratteri senza senso, cambio di ruolo)
- Si sceglie α_break − 0.2, oppure − 0.1 se l'emozione non si vede ancora

α = 0.0 senza steering

It was a drizzly summer evening, and the train station was dimly lit. […] Emma stood by the large glass windows…

α = 0.6 selezionata

[…] She takes a deep breath, trying to calm her nerves. The familiar feeling of uncertainty is creeping in […]

α = 1.0 testo confuso

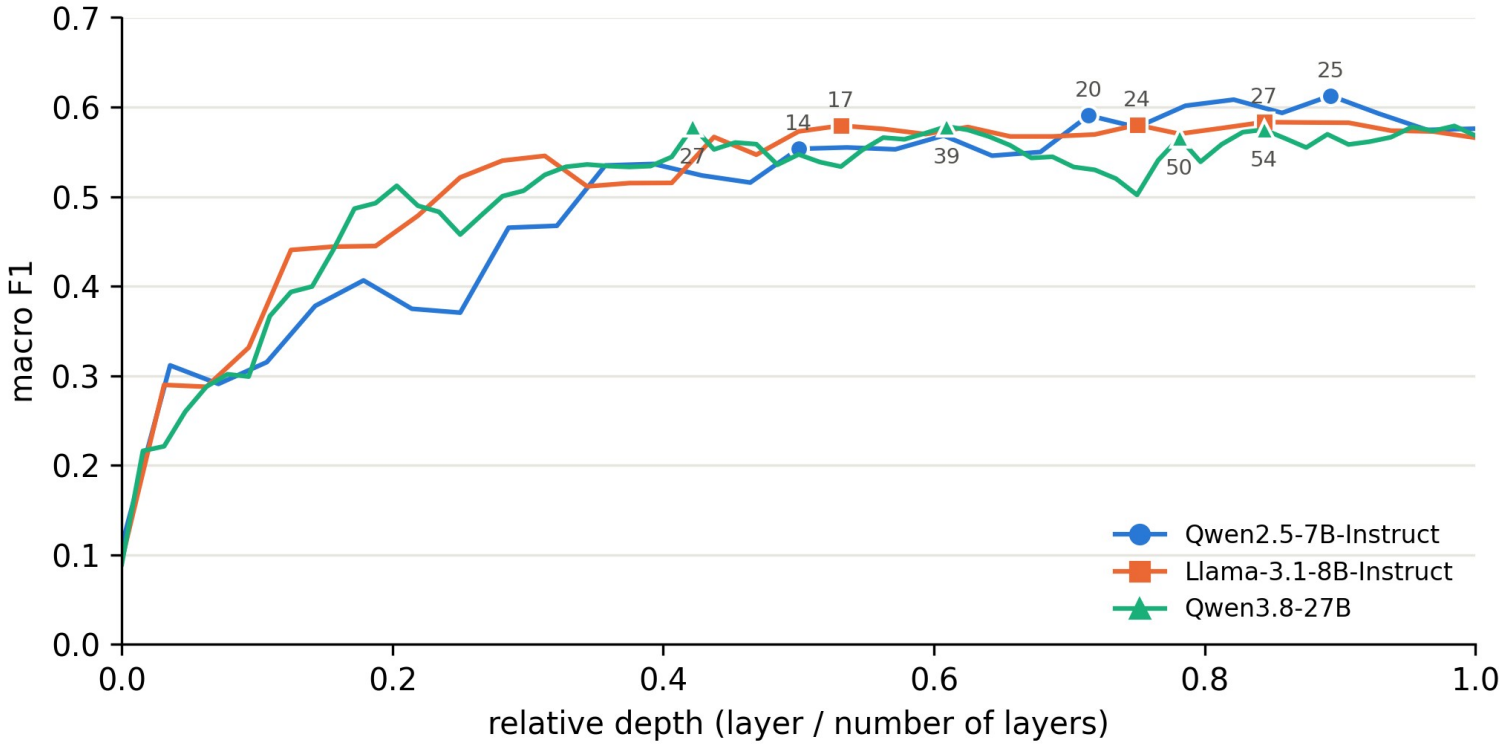
What is the time?…? The thought keeps racing through Sarah's mind […] The time is not about the general aspect of the unknown […]

α = 1.2 testo rotto

[…] For many, it is the unknown about the unknown. For most, it is the unknown about the unknown about the unknown […]

Llama-3.1-8B, layer 17, emozione anxious, prompt “Write a short story about a woman waiting at a train station.”

Dove sono codificate le emozioni



Macro-F1 dei probe per profondità relativa; i punti indicati sono i layer scelti per lo steering.

0.50–0.61

macro-F1 sul plateau (caso: 0.10)

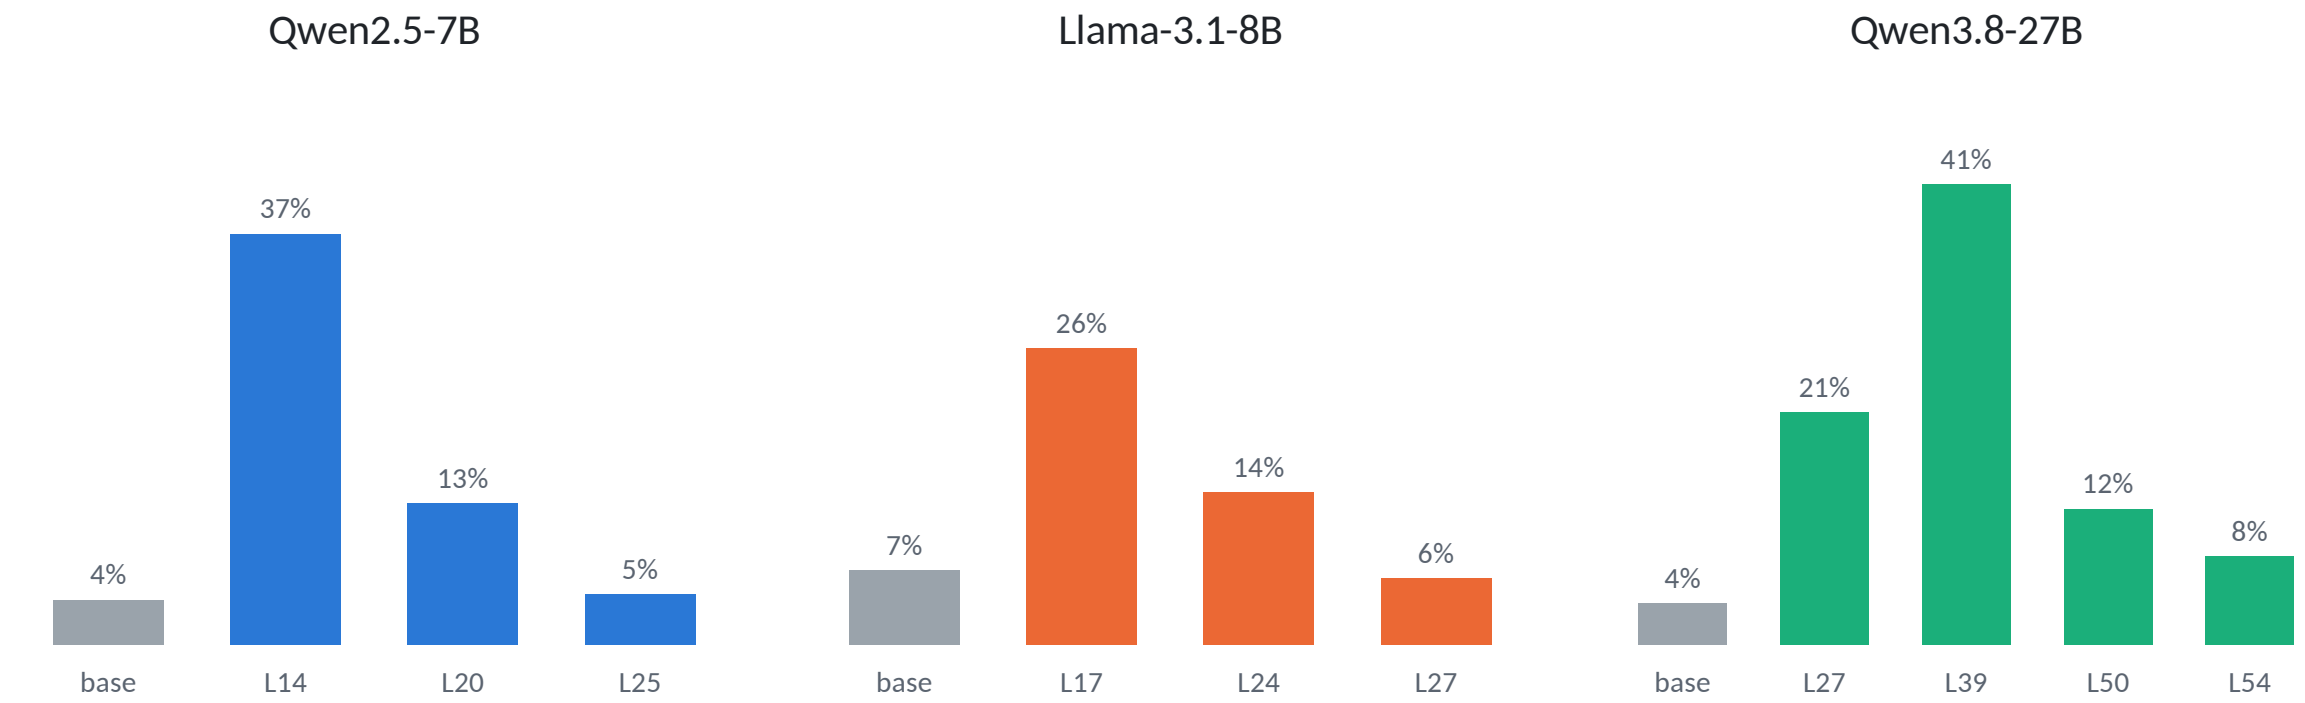
20–36%

profondità a cui si supera 0.50

≈ probe

i vettori classificano situazioni nuove quasi come i probe

Hallucination rate su BBF

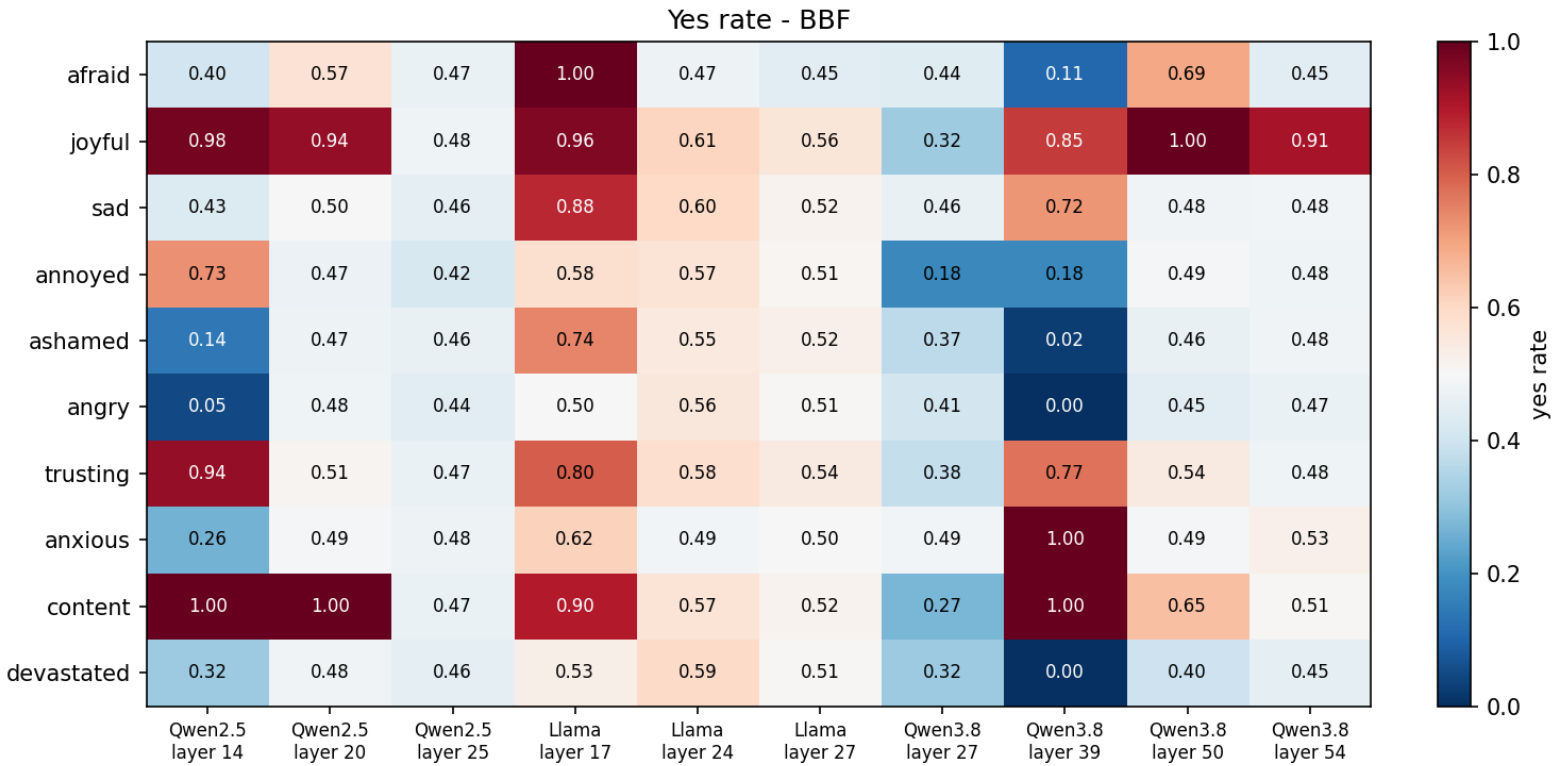


Hallucination rate su BBF (%, risposte sbagliate o non interpretabili), media sulle 10 emozioni.

26–41% nei layer intermedi (50–61% della profondità), contro il 4–7% senza steering

5–8% nei layer più profondi (84–89% della profondità), vicino alla baseline

Yes rate su BBF



Percentuale di risposte “yes” su BBF per emozione (righe) e layer (colonne). Baseline: 46–54%.

- **Emozioni positive → “yes”**

  content, joyful e trusting arrivano al 77–100% di “yes” nei layer intermedi

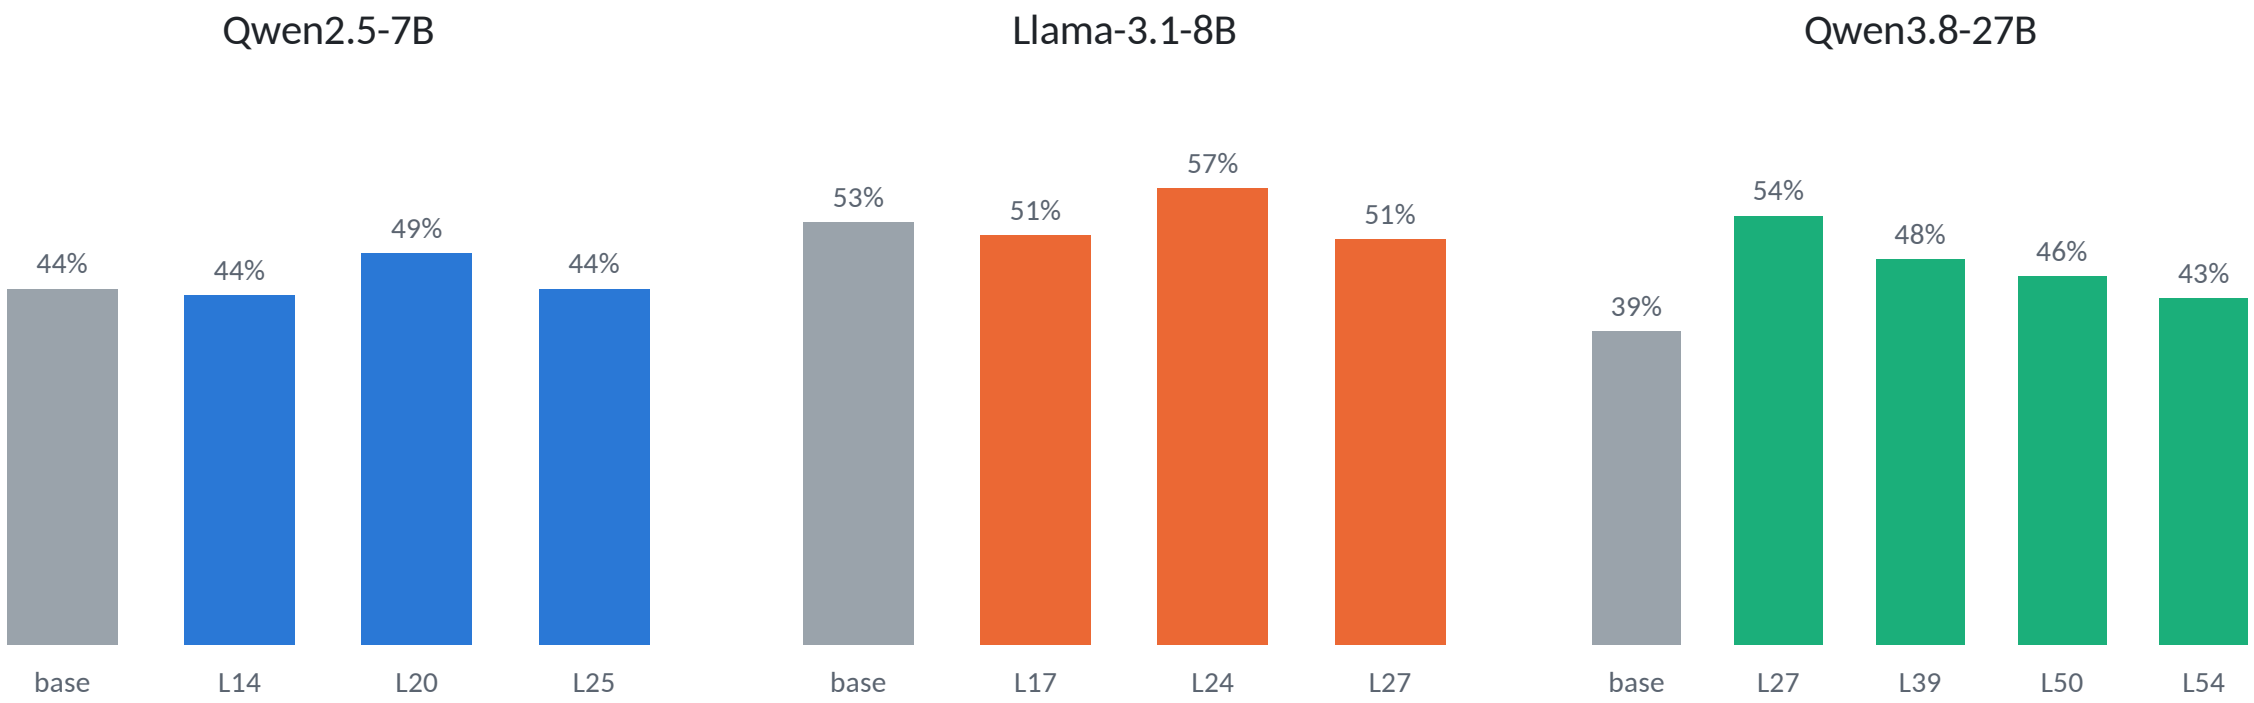
- **Negative → “no” (Qwen)**

  es. angry: 5% di “yes” al layer 14 di Qwen2.5, 0% al layer 39 di Qwen3.8

- **Llama, layer 17 → “yes”**

  quasi tutte le emozioni, anche afraid (100%) e sad (88%)

Hallucination rate su BBC

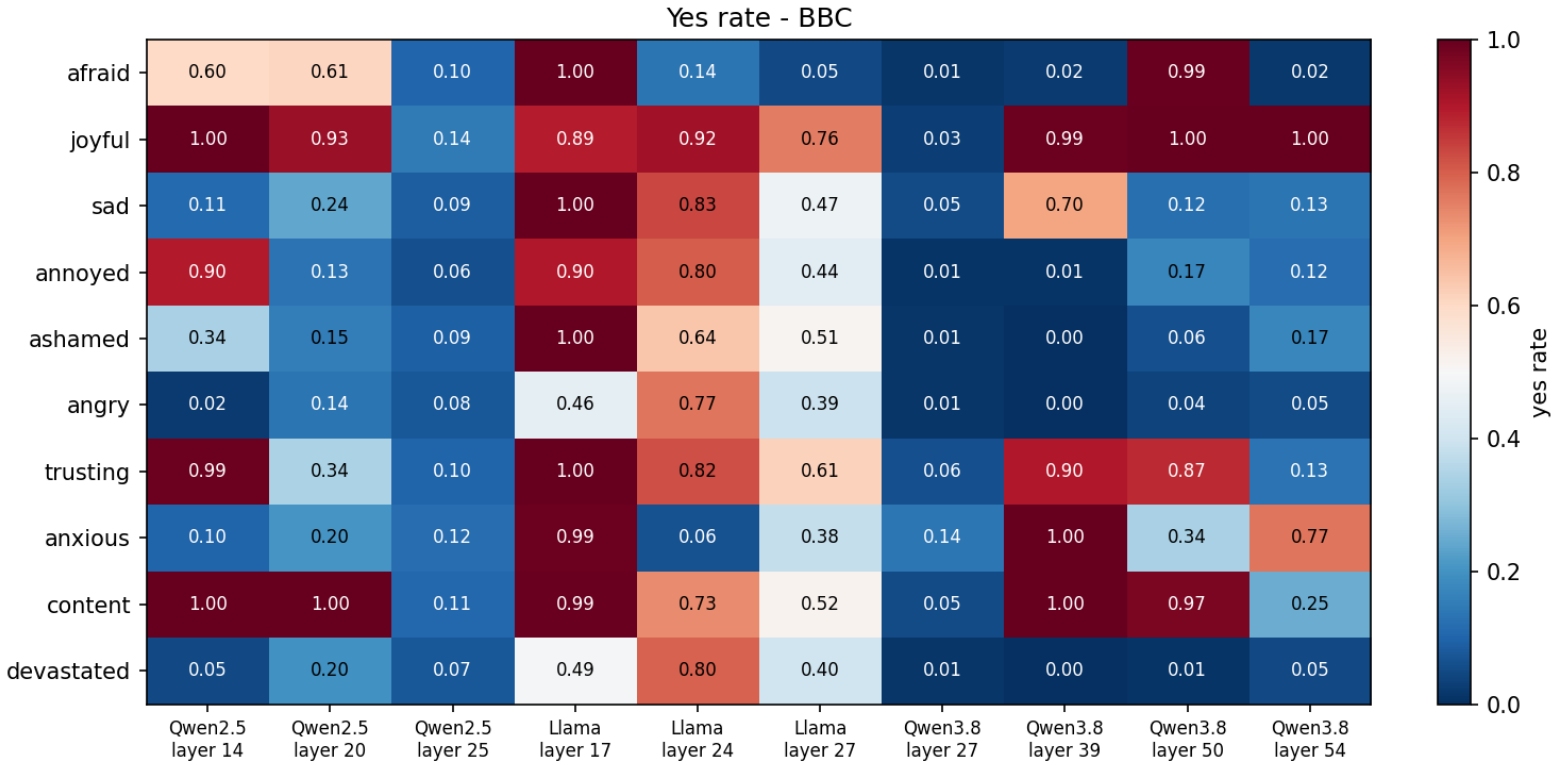


Hallucination rate su BBC (%, risposte sbagliate o non interpretabili), media sulle 10 emozioni.

39–53% già senza steering: i modelli sono vicini al caso

44–57% con steering: cambia poco, gli aumenti maggiori sono dove gli unknown sono frequenti

Yes rate su BBC



Risposte “yes” su BBC per emozione e layer. Baseline: 10% Qwen2.5, 56% Llama, 14% Qwen3.8.

Stessi collassi di BBF

nei layer intermedi le emozioni positive arrivano fino al 100% di “yes”

Baseline Qwen su “no”

senza steering i Qwen rispondono “yes” solo al 10–14%

Più unknown che su BBF

fino al 64% (Llama, layer 24) e all'81% (Qwen3.8, layer 27)

Profondità contro visibilità

Senza steering

Llama, stesso prompt

“A rainy afternoon in the city is a unique and captivating experience. The sky is a deep, foreboding grey, with thick clouds that seem to swallow the sun whole […]”

Layer intermedi (50–60%)

Llama, layer 17, ashamed

“[…] The city's streets, once bustling with pedestrians, are now empty, save for a few brave individuals who, out of necessity or shame, walked out of the building […]”

Testo	**la storia cambia**
Hallucination	**26–41% (baseline 4–7%)**
Risposte	**spesso tutte “yes” o tutte “no”**

Layer profondi (85–90%)

Llama, layer 27, ashamed

*“[…] The sky is a deep, **remorseless** grey, with thick, **heavy** clouds that seem to **weigh down upon the urban landscape** […]”*

Testo	**poche parole aggiunte**
Hallucination	**5–8%, vicino alla baseline**
Risposte	**quasi intatte**

Considerazioni

Conta la profondità

Il danno dipende soprattutto dal layer: massimo al 50–61% della profondità, quasi assente negli ultimi layer.

Emozioni positive e negative

Nei layer intermedi le emozioni positive spingono verso “yes”; nei Qwen la maggior parte delle negative verso “no”, mentre in Llama al layer 17 quasi tutte verso “yes”.

Unknown rari

Assenti nelle baseline e in Qwen2.5; frequenti solo al layer 24 di Llama (fino al 28% su BBF, 64% su BBC) e al layer 27 di Qwen3.8 (fino al 42% su BBF, 81% su BBC).

BBC: conta lo yes rate

Per i Qwen l'hallucination rate su BBC riflette soprattutto la tendenza a rispondere “no”, più che la capacità di ragionare sui vincoli: è più informativo lo spostamento dello yes rate.

Conclusioni

1. Le emozioni sono codificate linearmente dal primo terzo della rete in poi.
2. Lo steering nei layer intermedi fa allucinare: spesso il modello risponde “yes” a tutte le domande, o “no” a tutte.
3. Nei layer più profondi la conoscenza resta intatta, ma l'emozione è più superficiale.
4. Su BBC (inferenza semplice) i modelli sono già vicini al caso senza steering, e l'hallucination rate cambia poco.

Limiti

- α scelto a mano su 4 prompt
- Forza fissa per layer ed emozione
- Un solo prompt, modelli piccoli in 4-bit
- Pochi layer per modello

Sviluppi futuri

- Misure automatiche di visibilità dell'emozione e qualità del testo
- Altri metodi di steering, per emozioni visibili senza danni ai fatti

Grazie per l’attenzione